

模型建立

加入了Q矩阵，

$$\min_{P,E,Z,Q} \sum_{s=1}^S \|Z_s\|_* + \sum_{s=1}^S \delta \|E_s\|_{2,1} + \sum_{s=1}^S \kappa \|P_s X Q_s - P_s X Q_s Z_s\|_F^2 + \lambda \sum_{s \neq t} \text{HSIC}(Z_s, Z_t)$$

$$\text{s.t. } X Q_s = X Q_s Z_s + E_s, P_s^T P_s = I$$

其中：

$X = [X_1, X_2, \dots, X_S] \in \mathbb{R}^{D \times N}$, 是多模态数据，D为原始数据的特征数，N为所有模态数据的样本总数 $N = \sum^S n_s$

$X_s \in \mathbb{R}^{D \times n_s}$, 是每个模态的数据

$P_s \in \mathbb{R}^{d \times D}$, d为降维之后特征数

$Q_s \in \mathbb{R}^{N \times n_s}$, n_s 为单个模态数据的样本数

$Z_s \in \mathbb{R}^{n_s \times n_s}$

$E_s \in \mathbb{R}^{D \times n_s}$

更新优化

1. J

2. Z

3. P

$$\min_P \gamma \|PXQ - PXQZ\|_F^2$$

4. Q

$$\min_Q \gamma \|PXQ - PXQZ\|_F^2 + \frac{\mu}{2} \left\| XQ - XQZ - E + \frac{\Lambda}{\mu} \right\|_F^2$$

5. E

在线监控

得到每个模态的 P_s

1. 训练样本的“硬分配”标签

给定分配矩阵集合 $\{Q_s\}_{s=1}^S$ ，其中

$$Q_s \in \mathbb{R}^{N \times n_s},$$

计算每个训练样本 i 对第 s 模态的响应度：

$$W_{i,s} = \sum_{j=1}^{n_s} [Q_s]_{i,j}.$$


把所有模式并列得到权重矩阵 $W \in \mathbb{R}^{N \times S}$ ，然后对每行取最大：

$$\ell_i = \arg \max_{s=1, \dots, S} W_{i,s},$$

得到训练样本的硬标签向量

$$\boldsymbol{\ell} = [\ell_1, \dots, \ell_N]^\top.$$

基于 Q_s 的硬分配聚类结果



2. 基于空间连通性的重新编号

将训练样本在所选二维空间（此处取特征 1、2 维）视为点集合 $\{\mathbf{x}_i\}_{i=1}^N \subset \mathbb{R}^2$ 。

1. 对每个点 i 找到其 K 个最近邻索引 $\mathcal{N}(i)$ 。
2. 构造无向图邻接矩阵


$$A_{ij} = \begin{cases} 1, & j \in \mathcal{N}(i) \text{ or } i \in \mathcal{N}(j), \\ 0, & \text{otherwise,} \end{cases}$$

3. 在图上求**连通分量**，令


$$c_i \in \{1, \dots, C\}$$

表示点 i 所在的第 c_i 个连通组件。

基于空间连通区域的聚类结果 (Scatter)



基于空间连通区域的模式重新编号



3. 测试样本的模式预测


对每个测试样本 $\mathbf{y}_k$:

1. 在训练集上找到最邻近点索引

$$j^* = \arg \min_{1 \leq j \leq N} \|\mathbf{y}_k - \mathbf{x}_j\|_2.$$

2. 继承该训练点的标签:

$$\hat{s}_k = \ell_{j^*}.$$



4. 各模态均值与主成分协方差

令训练中归入模式 s 的样本集合为 $\mathcal{I}_s$ ，样本数 $n_s = |\mathcal{I}_s|$ 。

1. 均值

$$\boldsymbol{\mu}_s = \frac{1}{n_s} \sum_{i \in \mathcal{I}_s} \mathbf{x}_i.$$

2. 数据中心化

$$X_s = [\mathbf{x}_i]_{i \in \mathcal{I}_s} \in \mathbb{R}^{D \times n_s}, \quad \widetilde{X}_s = X_s - \boldsymbol{\mu}_s \mathbf{1}^\top.$$

3. 投影得分

$$T_s = P_s \widetilde{X}_s \in \mathbb{R}^{d \times n_s}.$$

4. 投影协方差

$$\Lambda_s = \frac{1}{n_s - 1} T_s T_s^\top \in \mathbb{R}^{d \times d}.$$

5. T^2 与 SPE 统计量

对任意（中心化后）样本 $\mathbf{z} \in \mathbb{R}^D$ 属于模式 s ：

1. Hotelling T^2

$$t = P_s \mathbf{z}, \quad T^2 = t^\top \Lambda_s^{-1} t.$$

2. SPE（平方预测误差）


$$E = (I - P_s^\top P_s) \mathbf{z}, \quad \text{SPE} = E^\top E.$$

6. 控制限的核密度估计

用训练集所有 T^2 （或 SPE）样本，做核密度估计求累积分布函数 $F(x)$ ，找到

$$L_\alpha = \inf\{x : F(x) \geq 1 - \alpha\},$$

作为置信水平 $1 - \alpha$ （如 99%）的控制限。



7. FDR 与 FAR

设第 s 个模式下故障发生区间为 $[t_s^{\text{fault}}, t_s^{\text{end}}]$ ，
基线区间为 $[t_s^{\text{start}}, t_s^{\text{fault}} - 1]$ 。则：

$$\text{FDR}_s = \frac{\#\{k : T_k^2 \geq L_\alpha, k \in [t_s^{\text{fault}}, t_s^{\text{end}}]\}}{t_s^{\text{end}} - t_s^{\text{fault}} + 1},$$

$$\text{FAR}_s = \frac{\#\{k : T_k^2 > L_\alpha, k \in [t_s^{\text{start}}, t_s^{\text{fault}} - 1]\}}{t_s^{\text{fault}} - t_s^{\text{start}}}.$$

同理对 SPE 统计量计算 $\text{FDR}_s^{\text{SPE}}$ 与 $\text{FAR}_s^{\text{SPE}}$ 。

以上即对应你的整段 MATLAB 代码中各部分的数学表达式与计算流程。